## Analiza UFC borbi

#### 2023-01-15

## Prvi pogled na podatke

Učitajmo skup podataka i pogledajmo koje značajke su dostupne.

```
data=read.csv("UFC.csv")
names(data)
```

```
##
     [1] "Winner"
                                             "title_bout"
##
     [3] "B_avg_KD"
                                             "B_avg_opp_KD"
##
     [5] "B_avg_SIG_STR_pct"
                                             "B_avg_opp_SIG_STR_pct"
##
     [7] "B_avg_TD_pct"
                                             "B_avg_opp_TD_pct"
##
     [9] "B_avg_SUB_ATT"
                                             "B_avg_opp_SUB_ATT"
##
    [11] "B_avg_REV"
                                             "B_avg_opp_REV"
##
    [13] "B_avg_SIG_STR_att"
                                             "B_avg_SIG_STR_landed"
    [15] "B_avg_opp_SIG_STR_att"
                                             "B_avg_opp_SIG_STR_landed"
    [17] "B_avg_TOTAL_STR_att"
                                             "B_avg_TOTAL_STR_landed"
##
    [19] "B_avg_opp_TOTAL_STR_att"
                                             "B_avg_opp_TOTAL_STR_landed"
##
    [21] "B_avg_TD_att"
                                             "B_avg_TD_landed"
    [23] "B_avg_opp_TD_att"
                                             "B_avg_opp_TD_landed"
    [25] "B_avg_HEAD_att"
                                             "B_avg_HEAD_landed"
##
##
    [27] "B_avg_opp_HEAD_att"
                                             "B_avg_opp_HEAD_landed"
##
    [29] "B_avg_BODY_att"
                                             "B_avg_BODY_landed"
                                             "B_avg_opp_BODY_landed"
##
   [31] "B_avg_opp_BODY_att"
                                             "B_avg_LEG_landed"
##
    [33] "B_avg_LEG_att"
##
    [35] "B_avg_opp_LEG_att"
                                             "B_avg_opp_LEG_landed"
##
    [37] "B_avg_DISTANCE_att"
                                             "B_avg_DISTANCE_landed"
    [39] "B_avg_opp_DISTANCE_att"
                                             "B_avg_opp_DISTANCE_landed"
##
    [41] "B_avg_CLINCH_att"
                                             "B_avg_CLINCH_landed"
##
                                             "B_avg_opp_CLINCH_landed"
   [43] "B_avg_opp_CLINCH_att"
   [45] "B_avg_GROUND_att"
                                             "B_avg_GROUND_landed"
   [47] "B_avg_opp_GROUND_att"
                                             "B_avg_opp_GROUND_landed"
##
    [49] "B_avg_CTRL_time.seconds."
                                             "B_avg_opp_CTRL_time.seconds."
##
    [51] "B_total_time_fought.seconds."
                                             "B_total_rounds_fought"
    [53] "B_total_title_bouts"
                                             "B_current_win_streak"
    [55] "B_current_lose_streak"
                                             "B_longest_win_streak"
##
    [57] "B_wins"
                                             "B_losses"
##
    [59] "B_draw"
                                             "B_win_by_Decision_Majority"
                                             "B_win_by_Decision_Unanimous"
    [61] "B_win_by_Decision_Split"
##
    [63] "B_win_by_KO.TKO"
                                             "B_win_by_Submission"
    [65] "B_win_by_TKO_Doctor_Stoppage"
##
                                             "B_Height_cms"
##
    [67] "B_Reach_cms"
                                             "B_Weight_lbs"
    [69] "R_avg_KD"
                                             "R_avg_opp_KD"
    [71] "R_avg_SIG_STR_pct"
                                             "R_avg_opp_SIG_STR_pct"
```

```
[73] "R_avg_TD_pct"
                                            "R_avg_opp_TD_pct"
##
    [75] "R_avg_SUB_ATT"
                                            "R_avg_opp_SUB_ATT"
    [77] "R_avg_REV"
                                            "R_avg_opp_REV"
                                            "R_avg_SIG_STR_landed"
   [79] "R_avg_SIG_STR_att"
##
    [81] "R_avg_opp_SIG_STR_att"
                                            "R_avg_opp_SIG_STR_landed"
   [83] "R_avg_TOTAL_STR_att"
                                            "R_avg_TOTAL_STR_landed"
##
   [85] "R_avg_opp_TOTAL_STR_att"
                                            "R_avg_opp_TOTAL_STR_landed"
    [87] "R_avg_TD_att"
                                            "R_avg_TD_landed"
##
##
    [89] "R_avg_opp_TD_att"
                                            "R_avg_opp_TD_landed"
   [91] "R_avg_HEAD_att"
##
                                            "R_avg_HEAD_landed"
   [93] "R_avg_opp_HEAD_att"
                                            "R_avg_opp_HEAD_landed"
   [95] "R_avg_BODY_att"
                                            "R_avg_BODY_landed"
  [97] "R_avg_opp_BODY_att"
                                            "R_avg_opp_BODY_landed"
## [99] "R_avg_LEG_att"
                                            "R_avg_LEG_landed"
## [101] "R_avg_opp_LEG_att"
                                            "R_avg_opp_LEG_landed"
## [103] "R_avg_DISTANCE_att"
                                            "R_avg_DISTANCE_landed"
## [105] "R_avg_opp_DISTANCE_att"
                                            "R_avg_opp_DISTANCE_landed"
## [107] "R_avg_CLINCH_att"
                                            "R_avg_CLINCH_landed"
## [109] "R_avg_opp_CLINCH_att"
                                            "R_avg_opp_CLINCH_landed"
## [111] "R_avg_GROUND_att"
                                            "R_avg_GROUND_landed"
## [113] "R_avg_opp_GROUND_att"
                                            "R_avg_opp_GROUND_landed"
## [115] "R_avg_CTRL_time.seconds."
                                            "R_avg_opp_CTRL_time.seconds."
## [117] "R_total_time_fought.seconds."
                                            "R_total_rounds_fought"
## [119] "R_total_title_bouts"
                                            "R current win streak"
## [121] "R_current_lose_streak"
                                            "R_longest_win_streak"
## [123] "R_wins"
                                            "R losses"
## [125] "R_draw"
                                            "R_win_by_Decision_Majority"
## [127] "R_win_by_Decision_Split"
                                            "R_win_by_Decision_Unanimous"
## [129] "R_win_by_KO.TKO"
                                            "R_win_by_Submission"
## [131] "R_win_by_TKO_Doctor_Stoppage"
                                            "R_Height_cms"
                                            "R_Weight_lbs"
## [133] "R_Reach_cms"
## [135] "B_age"
                                            "R_age"
## [137] "weight_class_Bantamweight"
                                            "weight_class_CatchWeight"
## [139] "weight_class_Featherweight"
                                            "weight_class_Flyweight"
## [141] "weight_class_Heavyweight"
                                            "weight_class_LightHeavyweight"
## [143] "weight_class_Lightweight"
                                            "weight_class_Middleweight"
## [145] "weight_class_OpenWeight"
                                            "weight class Welterweight"
## [147] "weight_class_WomenBantamweight"
                                            "weight_class_WomenFeatherweight"
## [149] "weight_class_WomenFlyweight"
                                            "weight_class_WomenStrawweight"
## [151] "B_Stance_Open.Stance"
                                            "B_Stance_Orthodox"
## [153] "B Stance Sideways"
                                            "B Stance Southpaw"
## [155] "B_Stance_Switch"
                                            "R_Stance_Open.Stance"
## [157] "R_Stance_Orthodox"
                                            "R_Stance_Sideways"
## [159] "R_Stance_Southpaw"
                                            "R_Stance_Switch"
```

Pogledajmo koliko zapisa i koliko značajki ima u skupu podataka.

#### dim(data)

```
## [1] 5902 160
```

## Pitanje 1.

# Možemo li očekivati završetak borbe nokautom ovisno o razlici u dužini ruku između boraca?

Učitavamo podatke i ostavljamo stupce koji će nam biti potrebni za testiranje ("B\_Reach\_cms", "R\_Reach\_cms", "win\_by"). Također stvaramo stupac razlika u kojem će biti pospremljena razlika u dužini ruku između boraca u toj borbi.

```
readfile = read.csv("combined.csv")
df = readfile[c("Winner", "B_Reach_cms", "R_Reach_cms", "win_by")]
razlika = df$B_Reach_cms - df$R_Reach_cms
df$razlika = razlika
```

Radimo deskriptivnu statistiku kako bi se bolje upoznali s podatcima.

```
win_by
       Winner
                        B_Reach_cms
                                       R_Reach_cms
##
##
   Length:5902
                              :147.3
                                              :152.4
                                                       Length:5902
                       Min.
                                       Min.
   Class : character
                       1st Qu.:177.8
                                       1st Qu.:177.8
                                                       Class : character
##
  Mode :character
                       Median :182.9
                                       Median :182.9
                                                       Mode :character
##
                       Mean
                              :182.8
                                       Mean
                                              :183.5
##
                       3rd Qu.:190.5
                                       3rd Qu.:190.5
##
                       Max.
                              :213.4
                                       Max.
                                              :213.4
##
      razlika
##
  Min.
          :-33.0200
   1st Qu.: -5.0800
##
## Median: 0.0000
          : -0.6227
## Mean
##
   3rd Qu.: 5.0800
## Max. : 27.9400
```


Tražimo nedostajuće vrijednosti ako ih ima.

```
for (col_name in names(df)){
  if (sum(is.na(df[,col_name])) >= 0){
    cat('Ukupno nedostajućih vrijednosti za varijablu ',col_name, ': ', sum(is.na(df[,col_name])),'\n')
  }
}
```


```
## Ukupno nedostajućih vrijednosti za varijablu Winner : 0
## Ukupno nedostajućih vrijednosti za varijablu B_Reach_cms : 0
## Ukupno nedostajućih vrijednosti za varijablu R_Reach_cms : 0
## Ukupno nedostajućih vrijednosti za varijablu win_by : 0
## Ukupno nedostajućih vrijednosti za varijablu razlika : 0
```

Preko histograma vidimo normalnu razdiobu podataka za duljinu ruku pojedinog borca i međusobnu razliku u duljinama ruku.


```
par(mfrow=c(2,2))
hist(df$B_Reach_cms,main='Reach in cms Blue', xlab='Reach', ylab='Frequency')
hist(df$R_Reach_cms,main='Reach in a cms Red', xlab='Reach', ylab='Frequency')
hist(df$razlika,main='Reach in cms histogram', xlab='Reach', ylab='Frequency')
barplot(table(df$win_by))
```



# **Boxplot of reaches for Blue and Red fighter**



## Boxplot of reaches for fights with and without KO/TKO



Preko drugog boxplota primjećujemo kako je srednja vrijednost, ujedno sa Q1 i Q3 u borbama koje su završile sa KO/TKO malo veća nego u ostalim borbama. Provest ćemo test kako bi utvrdili je li razlika značajna.

### Testiranje jednakosti srednjih vrijednosti dvije populacije

Kako bi proveli test, podatke ćemo podijeliti na brobe koje su završile sa KO/TKO i ostale borbe.

Hipoteze tada glase:

$$H_0: \mu_1 = \mu_2$$
  
 $H_1: \mu_1 < \mu_2$  ,  $\mu_1 > \mu_2$  ,  $\mu_1 \neq \mu_2$ 

Gdje je

 $\mu_1$ 

srednja vrijednost duljine ruku u borbama završenim nokautom i

 $\mu_2$ 


srednja vrijednost u borbama koje nisu završile nokautom.

Test o jednakosti srednjih vrijednosti dvije populacije u R-u je implementiran u funkciji t.test().

Kako bi mogli provesti test, moramo najprije provjeriti pretpostavke normalnosti i nezavisnosti uzorka. Obzirom da razmatramo dva različita borca, možemo pretpostaviti njihovu nezavisnost. Sljedeći korak je


provjeriti normalnost podataka koju najčešće provjeravamo: histgoramom, qq-plotom te KS-testom (kojim provjeravamo pripadnost podataka distribuciji).

## Histogram of reach difference for KO/TKO fights



```
hist(not_ko$razlika,
    main='Histogram of reach difference for not KO/TKO fights',
    xlab='Reach difference in cm')
```


# Histogram of reach difference for not KO/TKO fights



Histogrami upućuju na normalnost podataka. Normalnost možemo još provjeriti i qqplot-ovima ili testom koji ispituje normalnost.


```
par=(mfrow=c(1,2))

qqnorm(ko$razlika, pch = 1, frame = FALSE,main='KO/TKO')
qqline(ko$razlika, col = "steelblue", lwd = 2)
```



```
qqnorm(not_ko$razlika, pch = 1, frame = FALSE,main='Not KO/TKO')
qqline(not_ko$razlika, col = "steelblue", lwd = 2)
```

## **Not KO/TKO**



var(ko\$razlika)

## [1] 74.45139

var(not\_ko\$razlika)

## [1] 69.40993

## Test o jednakosti varijanci

Ako imamo dva nezavisna slučajna uzorka  $X_1^1,X_1^2,\dots X_1^{n_1}$  i  $X_2^1,X_2^2,\dots,X_2^{n_2}$  koji dolaze iz normalnih distribucija s varijancama  $\sigma_1^2$  i  $\sigma_2^2$ , tada slučajna varijabla

$$F = \frac{S_{X_1}^2/\sigma_1^2}{S_{X_2}^2/\sigma_2^2}$$

ima Fisherovu distribuciju s $(n_1-1,n_2-1)$ stupnjeva slobode, pri čemu vrijedi:

$$S_{X_1}^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (X_1^i - \bar{X}_1)^2, \quad S_{X_2}^2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (X_2^i - \bar{X}_2)^2.$$

Hipoteze testa jednakosti varijanci glase:

$$\begin{split} H_0: \sigma_1^2 &= \sigma_2^2 \\ H_1: \sigma_1^2 &< \sigma_2^2 \quad , \quad \sigma_1^2 > \sigma_2^2 \quad , \quad \sigma_1^2 \neq \sigma_2^2 \end{split}$$

#### var.test(ko\$razlika, not\_ko\$razlika)

```
##
## F test to compare two variances
##
## data: ko$razlika and not_ko$razlika
## F = 1.0726, num df = 1904, denom df = 3996, p-value = 0.07311
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
## 0.9934681 1.1593477
## sample estimates:
## ratio of variances
## 1.072633
```

p-vrijednost od 0.07311 nam govori da nećemo odbaciti hipotezu  $H_0$  da su varijance naša dva uzorka jednaka.

Provedimo sada t-test uz pretpostavku jednakosti varijanci. Test provodimo uz nivo značajnosti  $\alpha = 0.05$ .

```
t.test(ko$razlika, not_ko$razlika, alt = "greater", var.equal = TRUE)
```

#### Rezultat

Zbog veće p-vrijednosti (p-value = 0.9804) možemo zadržati  $H_0$  hipotezu o jednakosti prosječnih vrijednosti, odnosno možemo reći da s razlikom u dužini ruku boraca ne možemo očekivati završetak borbe nokautom.

## Pitanje 2.

## Razlikuje li se trajanje mečeva (u sekundama) između pojedinih kategorija?

Kako bismo provjerili jesu li srednje vrijednosti 3 ili više populacija jednake koristimo analizu varijance.

Na početku je potrebno učitati spojeni skup podataka i izračunati ukupno vrijeme trajanja borbi u novom stupcu *duration*.

```
data = read.csv(file = "combined.csv")
library(lubridate)
```

```
## Loading required package: timechange

##
## Attaching package: 'lubridate'

## The following objects are masked from 'package:base':

##
## date, intersect, setdiff, union

data$last_round_time=as.numeric(as.period(ms(data$last_round_time), unit = "sec"))

data$duration = (data$last_round-1)*5*60+data$last_round_time
```

### Pretpostavke

Pretpostavke ANOVA-e su:

- normalna razdioba podataka
- homoskedastičnost populacija
- nezavisnost podataka u uzorcima.

ANOVA je robusna na blaga odstupanja od pretpostavke normalnosti i homoskedastičnosti pod uvjetom da su veličine uzoraka podjednake.

U slijedećem isječku koda ćemo provjeriti jesu li veličine uzoraka približno jednake.

```
nrow(data[data$weight_class_Flyweight==1,])

## [1] 226

nrow(data[data$weight_class_Bantamweight==1,])

## [1] 462

nrow(data[data$weight_class_Featherweight==1,])

## [1] 539

nrow(data[data$weight_class_Lightweight==1,])

## [1] 1072

nrow(data[data$weight_class_Welterweight==1,])


## [1] 1066
```


```
nrow(data[data$weight_class_Middleweight==1,])
## [1] 803
nrow(data[data$weight_class_LightHeavyweight==1,])
## [1] 559
nrow(data[data$weight_class_Heavyweight==1,])
## [1] 573
nrow(data[data$weight_class_OpenWeight==1,])
## [1] 86
nrow(data[data$weight_class_WomenFlyweight==1,])
## [1] 110
nrow(data[data$weight_class_WomenBantamweight==1,])
## [1] 149
nrow(data[data$weight_class_WomenFeatherweight==1,])
## [1] 16
nrow(data[data$weight_class_WomenStrawweight==1,])
## [1] 190
Vidimo da veličine uzoraka nisu jednake.
Zatim ćemo provjeriti dolaze li podaci iz normalnih distribucija Lillieforsovom inačicom Kolmogorov-
Smirnovljevog testa.
require(nortest)
## Loading required package: nortest
lillie.test(data$duration)
##
##
   Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: data$duration
## D = 0.24115, p-value < 2.2e-16
```

```
lillie.test(data$duration[data$weight_class_Flyweight==1])
##
   Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: data$duration[data$weight_class_Flyweight == 1]
## D = 0.30543, p-value < 2.2e-16
lillie.test(data$duration[data$weight class Bantamweight==1])
##
  Lilliefors (Kolmogorov-Smirnov) normality test
## data: data$duration[data$weight_class_Bantamweight == 1]
## D = 0.27288, p-value < 2.2e-16
lillie.test(data$duration[data$weight_class_Featherweight==1])
##
## Lilliefors (Kolmogorov-Smirnov) normality test
## data: data$duration[data$weight_class_Featherweight == 1]
## D = 0.2944, p-value < 2.2e-16
lillie.test(data$duration[data$weight_class_Lightweight==1])
##
  Lilliefors (Kolmogorov-Smirnov) normality test
## data: data$duration[data$weight_class_Lightweight == 1]
## D = 0.27112, p-value < 2.2e-16
lillie.test(data$duration[data$weight_class_Welterweight==1])
##
## Lilliefors (Kolmogorov-Smirnov) normality test
## data: data$duration[data$weight_class_Welterweight == 1]
## D = 0.24605, p-value < 2.2e-16
lillie.test(data$duration[data$weight_class_Middleweight==1])
##
   Lilliefors (Kolmogorov-Smirnov) normality test
## data: data$duration[data$weight_class_Middleweight == 1]
## D = 0.20364, p-value < 2.2e-16
```

```
lillie.test(data$duration[data$weight_class_LightHeavyweight==1])
##
  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: data$duration[data$weight class LightHeavyweight == 1]
## D = 0.20125, p-value < 2.2e-16
lillie.test(data$duration[data$weight_class_Heavyweight==1])
##
  Lilliefors (Kolmogorov-Smirnov) normality test
## data: data$duration[data$weight_class_Heavyweight == 1]
## D = 0.12936, p-value < 2.2e-16
lillie.test(data$duration[data$weight_class_WomenStrawweight==1])
##
##
  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: data$duration[data$weight_class_WomenStrawweight == 1]
## D = 0.35527, p-value < 2.2e-16
lillie.test(data$duration[data$weight_class_WomenFlyweight==1])
##
## Lilliefors (Kolmogorov-Smirnov) normality test
## data: data$duration[data$weight_class_WomenFlyweight == 1]
## D = 0.30419, p-value < 2.2e-16
lillie.test(data$duration[data$weight_class_WomenBantamweight==1])
##
## Lilliefors (Kolmogorov-Smirnov) normality test
## data: data$duration[data$weight_class_WomenBantamweight == 1]
## D = 0.3205, p-value < 2.2e-16
lillie.test(data$duration[data$weight_class_WomenFeatherweight==1])
##
   Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: data$duration[data$weight_class_WomenFeatherweight == 1]
## D = 0.25308, p-value = 0.007279
```

Intuitivnu potvrdu rezultata iz prethodnog testa možemo vidjeti u slijedećim histogramima.





Uvodimo značajku weight\_class kako bismo elegantnije mogli napisati naredbu za provođenje Bartlettovog testa.

Slijedeća pretpostavka koju trebamo provjeriti je homoskedastičnost populacija i nju testiramo Bartlettovim testom.

```
bartlett.test(data$duration ~ data$weight_class)
##
##
   Bartlett test of homogeneity of variances
##
## data: data$duration by data$weight_class
## Bartlett's K-squared = 28.438, df = 12, p-value = 0.004771
Zaključujemo da populacije nemaju jednake varijance.
var((data$duration[data$weight_class_Flyweight == 1]))
## [1] 111375.4
var((data$duration[data$weight_class_Bantamweight==1]))
## [1] 115919.8
var((data$duration[data$weight_class_Featherweight==1]))
## [1] 121757.5
var((data$duration[data$weight_class_Lightweight==1]))
## [1] 118367.7
var((data$duration[data$weight_class_Welterweight==1]))
## [1] 131827.2
var((data$duration[data$weight_class_Middleweight==1]))
## [1] 125206
var((data$duration[data$weight_class_LightHeavyweight==1]))
## [1] 145085.2
var((data$duration[data$weight_class_Heavyweight==1]))
## [1] 138060.4
var((data$duration[data$weight_class_WomenFlyweight==1]))
## [1] 108238.4
```

```
var((data$duration[data$weight_class_WomenBantamweight==1]))
## [1] 107707.7
```

```
var((data$duration[data$weight_class_WomenFeatherweight==1]))
```

## [1] 286926.1

```
var((data$duration[data$weight_class_WomenStrawweight==1]))
```


## [1] 103843.3

```
var((data$duration[data$weight_class_OpenWeight==1]))
```

## [1] 64910.04

U slijedećim box plotovima možemo vidjeti podatke o trajanju borbi za svaku težinsku kategoriju.

```
# Graficki prikaz podataka
boxplot(data$duration ~ data$weight_class, las=2)
```



### Test

U konačnici provodimo ANOVA-u.

Naše hipoteze su:

```
H_0: \mu_1 = \mu_2 = \dots = \mu 13
```

 $H_1$ : Barem jedna od sredina je različita od ostalih.

Test provodimo uz nivo značajnosti od 0.05.

```
# Test
a = aov(data$duration ~ data$weight_class)
summary(a)
```

### Rezultat

Iznimno mala p-vrijednost znači da odbacujemo  $H_0$  u korist  $H_1$ , odnosno da prihvaćamo da srednje vrijednosti trajanja borbi nisu jednake u svim kategorijama.

## Pitanje 3.

## Traju li (u rundama) borbe za titulu duže od ostalih borbi u natjecanju?

Na početku je potrebno razdvojiti podatke na dva skupa: 'borbe za titulu' i 'ostale borbe'.

```
ufc=read.csv("combined.csv")

ufc_title=ufc %>% filter(grepl("Title",Fight_type,ignore.case = TRUE))
ufc_not_title=ufc %>% filter(!grepl("Title",Fight_type,ignore.case = TRUE))
```

```
mean(ufc_title$last_round)
```

```
## [1] 2.983333
```

```
mean(ufc_not_title$last_round)
```


```
## [1] 2.27048
```

Na prvi pogled uistinu izgleda da su borbe za titulu u prosjeku duže od ostalih borbi. Pomoću statističkog testa možemo vidjeti je li ta razlika značajna.

Prikažimo podatke grafički:


```
df=data.frame(ufc_title$last_round)
library(ggplot2)
p=ggplot(df,aes(ufc_title$last_round,ufc_title$last_round))+geom_bar(stat="identity",width=1)+ggtitle(".p + theme(
    plot.title = element_text(hjust = 0.5),
    axis.title.y = element_blank()
)
```

## Histogram trajanja borbi za titulu (u rundama)



```
df=data.frame(ufc_not_title$last_round)
p=ggplot(df,aes(ufc_not_title$last_round,ufc_not_title$last_round))+geom_bar(stat="identity",width=1)+gp
p + theme(
plot.title = element_text(hjust = 0.5),
axis.title.y = element_blank()
)
```

## Histogram trajanja ostalih borbi (u rundama)



Pošto se radi o diskretnim podacima, oni ne mogu biti normalno raspoređeni. U tom slučaju koriste se neparametarski testovi.

nrow(ufc\_title)

## [1] 360

nrow(ufc\_not\_title)

## [1] 5542

Pošto je broj uzoraka jedne populacije veći od broja uzoraka druge, koristimo Mann-Whitney-Wilcoxonov test i možemo pretpostaviti nezavisnost uzoraka.

 ${\bf Hipoteze~su:}$ 

 $H_0: \tilde{\mu_1} = \tilde{\mu_2}$ 

 $H_1: \tilde{\mu_1} > \tilde{\mu_2}$ 

Test provodimo uz nivo značajnosti od 0.05.

wilcox.test(ufc\_title\$last\_round,ufc\_not\_title\$last\_round,alternative = "greater")

##

## Wilcoxon rank sum test with continuity correction

```
##
## data: ufc_title$last_round and ufc_not_title$last_round
## W = 1215163, p-value = 1.986e-14
## alternative hypothesis: true location shift is greater than 0
```

#### Rezultat

Odbacujemo  $H_0$  u korist  $H_1$ : medijan trajanja(u rundama) borba za titulu veći je od medijana trajanja ostalih borba.

## Pitanje 4.

## Mogu li dostupne značajke predvidjeti pobjednika?

```
ufcBorbe <- read.csv("UFC.csv")
# dim(ufcBorbe)  # broj redaka, broj stupaca (broj primjera, broj varijabli)
# nrow(ufcBorbe)  # broj redaka
# ncol(ufcBorbe)  # broj stupaca -> što daje length?
colNames <- names(ufcBorbe)  # imena stupaca
# print(colNames)</pre>
```

Iz učitanih podataka, može se vidjeti da će stupac *Winner* sadržavati vrijednosti koje želimo predvidjeti pomoću ostalih značajki. Također je potrebno zamijeniti vrijednosti stupca *title\_bout* i *Winner*, true i false, s vrijednostima 1 i 0 respektivno.

Isto tako, potrebno je odrediti koje varijable su međusobno zavisne jer njihova zavisnost može dati netočne i neprecizne rezultate. Da bi odredili koje su varijable međusobno zavisne, za provjeru koreliranosti varijabli, koristili smo Pearsonov koeficijent korelacije. Pearsonov koeficijent korelacije  $\boldsymbol{r}$  računa koliko su dvije varijable jako povezane i u kojem smjeru. Njegova vrijedost je u intervalu <-1, 1> te što je bliže 1 ili -1 to je zavisnost varijabli veća, takve varijable želimo izbaciti.

```
newData <- data.frame(matrix(nrow = nrow(ufcBorbe)))</pre>
newData[colNames[1]] <- ufcBorbe[, 1] # izlazna varijabla - stupac Winner
newData[colNames[2]] <- ufcBorbe[, 2]</pre>
                                        # title bout
#Promjena vrijednosti značajki Winnier i title_bout
newData$Winner[newData$Winner=="Blue"] <-1
newData$Winner[newData$Winner=="Red"]<-0
newData$Winner<-as.numeric(newData$Winner)</pre>
newData$title_bout[newData$title_bout==TRUE]<-1</pre>
newData$title_bout[newData$title_bout==FALSE]<-0
newData$title_bout<-as.numeric(newData$title_bout)</pre>
prevelikCoef <- FALSE</pre>
for(i in 3:160) {
    x <- as.numeric(ufcBorbe[, i]) # novi stupac koji pokusavamo dodati ako nije liearno zavisan o pri
    for(j in 2:ncol(newData)) {
        if(!prevelikCoef) {
            y <- as.numeric(newData[, j])
```

```
suppressWarnings(coef1 <- cor(x, y, method = "pearson"))
    if((!is.na(coef1)) && ((coef1 < -0.6) || (coef1 > 0.6))) {
        # print(pasteO("Usao za ", colNames[i]))
        prevelikCoef <- TRUE
    }
} else {
    break
}
if(!prevelikCoef) {
    newData[colNames[i]] <- ufcBorbe[, i]
}
prevelikCoef <- FALSE
}
newData <- newData[, ! names(newData) %in% c("matrix.nrow...nrow.ufcBorbe..")]
# write.table(newData, file = "tablica.txt", sep = ",")</pre>
```

#### Logistička regresija

Nakon što je određeno koje značajke ćemo uzeti, potrebno je istrenirati model na određenom skupu podataka a onda testirati njegovu točnost na drugim podacima. U tu svrhu, smo ulazni skup podataka podijelili na skup za treniranje (70 posto ulaznih podataka) i skup za testiranje (preostalih 30 posto).

Pozivom ugrađene funkcije za treniranje generičkih linearnih modela, glm, kojoj smo proslijedili sve značajke koje ćemo koristit za predviđanje izlazne varijable.

```
require(caret)
```

## Loading required package: caret

## Predikcija

Sada naučeni model možemo koristiti za predviđanje još neviđenih podataka, skup podataka za testiranje. Kao rezultat toga ćemo dobiti matricu konfuzije, oblika

$$\begin{array}{c|cccc} & \hat{Y}=0 & \hat{Y}=1\\ \hline Y=0 & TN & FP\\ \hline Y=1 & FN & TP \end{array}$$

Dakle pokazuje za koliko primjera, koji su trebali imati izlaz 1, je model vratio 1 (true positive, TP), za koje je vratio 0 (false negative, FN). Isto vrijedi i za promjere s izlazom 0, ako je za njih model vratio isto 0 (true negative, TN) ili je vratio 1 (false positive, FP).

```
Na temelju tih vrijednosti možemo izračunati sljedeće vrijednosti: - točnost (eng. accuracy): \frac{TP+TN}{TP+FP+TN+FN} \text{ - preciznost (eng. precision): } \frac{TP}{TP+FP} \text{ - odziv (eng. recall): } \frac{TP}{TP+FN} \text{ - specifičnost (eng. specificity): } \frac{TN}{TN+FP}
```

Točnost govori koliko je od svih primjera točno klasificiranih (dakle da je očekivani izlaz bio 0 ili 1 i da je za njih model isto vratio 0 ili 1 respektativno). Preciznost govori koliko je od svih primjera koje je model klasificirao s izlazom 1, a da je njihov očekivani izlaz bio isto 1. Odziv pokazuje koliko je primjera od svih koji su trebali biti klasificirani kao 1, model stvarno i klasificirao kao 1. Na kraju, specifičnost pokazuje udio primjera koji su točno klasificirani kao 0

```
# predict(logreg.mdl, testSet)
yHat <- logreg.mdl$fitted.values > 0.5
tab <- table(trainSet$Winner, yHat)</pre>
tab
##
      yHat
##
       FALSE TRUE
##
        2514
              268
         962 380
accuracy = sum(diag(tab)) / sum(tab)
precision = tab[2,2] / sum(tab[,2])
recall = tab[2,2] / sum(tab[2,])
specificity = tab[1,1] / sum(tab[,1])
accuracy
## [1] 0.7017459
precision
## [1] 0.5864198
recall
## [1] 0.2831595
specificity
```

## [1] 0.7232451

### Test omjera izglednosti (likelihood ratio test)

Moguće je odabrati manji broj značajki, tako da se smanji prihvaćeni interval Pearsonovog koeficijenta korelacije. Dobiveni rezultat bi tada usporedili s prvim modelom i vidjeli koji bolje predviđa. Ovaj pristup se naziva test omjera izglednosti

```
logreg.mdl.2 = glm(Winner ~ title_bout + B_avg_KD + B_avg_opp_KD + B_avg_SIG_STR_pct + B_avg_opp_SIG_ST
                 data = trainSet, family=binomial())
yHat <- logreg.mdl.2$fitted.values > 0.5
tab <- table(trainSet$Winner, yHat)</pre>
tab
##
##
       FALSE TRUE
##
       2557 225
     1 1082 260
##
accuracy = sum(diag(tab)) / sum(tab)
precision = tab[2,2] / sum(tab[,2])
recall = tab[2,2] / sum(tab[2,])
specificity = tab[1,1] / sum(tab[,1])
accuracy
## [1] 0.6830747
precision
## [1] 0.5360825
recall
## [1] 0.1937407
specificity
## [1] 0.7026656
anova(logreg.mdl, logreg.mdl.2, test = "LRT")
## Analysis of Deviance Table
##
## Model 1: Winner ~ title_bout + B_avg_KD + B_avg_opp_KD + B_avg_SIG_STR_pct +
       B_avg_opp_SIG_STR_pct + B_avg_TD_pct + B_avg_opp_TD_pct +
##
##
       B_avg_SUB_ATT + B_avg_opp_SUB_ATT + B_avg_REV + B_avg_opp_REV +
##
       B_avg_SIG_STR_att + B_avg_opp_TOTAL_STR_landed + B_avg_TD_att +
##
       B_avg_opp_TD_att + B_avg_LEG_att + B_avg_opp_LEG_att + B_avg_CLINCH_att +
       B_avg_opp_CLINCH_att + B_avg_GROUND_att + B_avg_opp_GROUND_att +
##
```

```
B_avg_opp_CTRL_time.seconds. + B_total_rounds_fought + B_total_title_bouts +
##
##
       B_current_win_streak + B_current_lose_streak + B_draw + B_win_by_Decision_Majority +
       B win by Decision Split + B win by Submission + B win by TKO Doctor Stoppage +
##
##
       B_Height_cms + R_avg_KD + R_avg_opp_KD + R_avg_SIG_STR_pct +
       R_avg_opp_SIG_STR_pct + R_avg_TD_pct + R_avg_opp_TD_pct +
##
##
       R_avg_SUB_ATT + R_avg_opp_SUB_ATT + R_avg_REV + R_avg_opp_REV +
##
       R avg SIG STR att + R avg opp TOTAL STR landed + R avg TD att +
       R_avg_opp_TD_att + R_avg_LEG_att + R_avg_opp_LEG_att + R_avg_CLINCH_att +
##
##
       R_avg_opp_CLINCH_att + R_avg_GROUND_att + R_avg_opp_GROUND_att +
##
       R_total_rounds_fought + R_total_title_bouts + R_current_win_streak +
##
       R_current_lose_streak + R_draw + R_win_by_Decision_Majority +
##
       R_win_by_Decision_Split + R_win_by_Submission + R_win_by_TKO_Doctor_Stoppage +
       B_age + R_age + weight_class_Bantamweight + weight_class_CatchWeight +
##
       weight_class_Featherweight + weight_class_Flyweight + weight_class_Heavyweight +
##
##
       weight_class_LightHeavyweight + weight_class_Lightweight +
##
       weight_class_Middleweight + weight_class_OpenWeight + weight_class_Welterweight +
##
       weight_class_WomenBantamweight + weight_class_WomenFeatherweight +
       weight class WomenFlyweight + weight class WomenStrawweight +
##
       B_Stance_Open.Stance + B_Stance_Orthodox + B_Stance_Sideways +
##
       B Stance Switch + R Stance Open.Stance + R Stance Orthodox +
##
##
       R_Stance_Sideways + R_Stance_Switch
## Model 2: Winner ~ title_bout + B_avg_KD + B_avg_opp_KD + B_avg_SIG_STR_pct +
       B_avg_opp_SIG_STR_pct + B_avg_TD_pct + B_avg_opp_TD_pct +
##
##
       B_avg_SUB_ATT + B_avg_opp_SUB_ATT + B_avg_REV + B_avg_opp_REV +
       B_avg_SIG_STR_att + B_avg_TD_att + B_avg_opp_TD_att + B_avg_GROUND_att +
##
##
       B_avg_opp_GROUND_att + B_total_rounds_fought + B_current_lose_streak +
##
       B_draw + B_win_by_Decision_Majority + B_win_by_TKO_Doctor_Stoppage +
##
       B_Height_cms + R_avg_KD + R_avg_opp_KD + R_avg_SIG_STR_pct +
##
       R_avg_opp_SIG_STR_pct + R_avg_TD_pct + R_avg_opp_TD_pct +
       R_avg_SUB_ATT + R_avg_opp_SUB_ATT + R_avg_REV + R_avg_opp_REV +
##
       R_avg_SIG_STR_att + R_avg_TD_att + R_avg_opp_TD_att + R_avg_CLINCH_att +
##
##
       R_avg_GROUND_att + R_avg_opp_GROUND_att + R_total_title_bouts +
##
       R_current_lose_streak + R_draw + R_win_by_Decision_Majority +
##
       R_win_by_TKO_Doctor_Stoppage + B_age + weight_class_Bantamweight +
       weight_class_CatchWeight + weight_class_Featherweight + weight_class_Flyweight +
##
##
       weight_class_LightHeavyweight + weight_class_Lightweight +
##
       weight class Middleweight + weight class OpenWeight + weight class Welterweight +
##
       weight_class_WomenBantamweight + weight_class_WomenFeatherweight +
       weight class WomenFlyweight + weight class WomenStrawweight +
##
##
       B_Stance_Open.Stance + B_Stance_Orthodox + B_Stance_Sideways +
       B Stance Switch + R Stance Open.Stance + R Stance Orthodox +
##
       R Stance Sideways + R Stance Switch
##
##
     Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1
          4041
                   4664.8
          4060
## 2
                   4800.3 -19 -135.46 < 2.2e-16 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
```

## Rezultat

Rezultati pokazuju da su se vrijednosti mjera kvalitete smanjile, pala je točnost i preciznost modela. S obzirom na te rezultate, prijašnji model *logreg.mdl* će biti prihvaćen.

## Pitanje 5.

# Postoji li razlika u udjelu borbi koje završe kao KO/TKO ovisno o tome stoje li borci u istim ili različitim gardovima?

Stvaramo stupac stance koji ima vrijednost Same ako borci stoje u istim gardovima i different ako stoje u različitim.

```
data = read.csv(file = "combined.csv")
data$stance = with(data, ifelse(B_Stance_Open.Stance==R_Stance_Open.Stance & B_Stance_Orthodox==R_Stance
nrow(data[data$stance=="Same",])

## [1] 3718
nrow(data[data$stance=="Same" & data$win_by=="KO/TKO",])

## [1] 1188
nrow(data[data$stance=="Different",])

## [1] 2184
nrow(data[data$stance=="Different" & data$win_by=="KO/TKO",])

## [1] 717
```

#### Test

Kao procjenitelje za proporcije p borbi koje su završile kao KO/TKO koristiti ćemo  $\hat{P} = \frac{X}{n}$ , gdje X predstavlja broj borbi koje su završile kao KO/TKO od ukupno n borbi.

Prema Centralnom graničnom teoremu znamo da, za dovoljno veliki n,  $\hat{P}$  ima aproksimativno normalnu distribuciju s očekivanjem p i varijancom  $\frac{pq}{n}$ .

Označimo procjenitelj udjela borbi koje završavaju kao KO/TKO i u kojima borci stoje u istim gardovima s  $\hat{P}_1$  i procjenitelj udjela borbi koje završavaju kao KO/TKO i u kojima borci stoje u različitim gardovima s  $\hat{P}_2$ .

Iz stabilnosti normalne slučajne varijable na sume slijedi da  $\hat{P}_1 - \hat{P}_2$  također ima aproksimativno normalnu distribuciju s očekivanjem  $p_1 - p_2$  i varijancom  $\frac{p_1q_1}{n_1} + \frac{p_2q_2}{n_2}$ .

Za testiranje ćemo koristiti statistiku

$$Z = \frac{(\hat{P}_1 - \hat{P}_2) - (p_1 - p_2)}{\sqrt{\frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2}}}.$$

Naše hipoteze su:

 $H_0: p_1 = p_2$  $H_1: p_1 \neq p_2.$ 

Test provodimo uz nivo značajnosti  $\alpha = 0.05$  i zbog oblika  $H_1$  koristimo dvostranu alternativu.

#### Rezultat

P-vrijednost iznosi 0.5048, te zbog toga uz nivo značajnosti 0.05 ne možemo odbaciti hipotezu  $H_0$ . Drugim riječima, prihvaćamo da su udjeli borbi koje završavaju kao KO/TKO jednaki neovisno o razlici u gardovima boraca.

## Pitanje 6.

Postoji li razlika u udjelu borbi koje završavaju submissionom ovisno o tome održava li se event u Brazilu ili ne?

Prvo moramo podijeliti podatke po lokaciji.

```
library(stringr)
data = read.csv(file = "combined.csv")

data_brazil=data[str_detect(data$location, "Brazil"),]
data_not_brazil=data[!str_detect(data$location, "Brazil"),]
```

Pogledajmo ukupan broj borbi u oba skupa i broj borbi koje su završile submissionom.

```
nrow(data_brazil)

## [1] 420

nrow(data_brazil[data_brazil$win_by=="Submission",])

## [1] 103

nrow(data_not_brazil)
```

## [1] 5482

```
nrow(data_not_brazil[data_not_brazil$win_by=="Submission",])
```

```
## [1] 1108
```

## Test

Test koji ćemo provesti gotovo je identičan onom u 5. pitanju. Jedina razlika je u hipotezama. Naime, logično bi bilo pretpostaviti da je udio submissiona na eventima u Brazilu veći, pa su naše hipoteze:

```
H_0: p_{Brazil} = p_{Ostalo} H_1: p_{Brazil} > p_{Ostalo}. Test provodimo uz razinu značajnosti 0.05.
```

```
res <- prop.test(x = c(103, 1108), n = c(420, 5482), alternative="greater")
res
```

```
##
## 2-sample test for equality of proportions with continuity correction
##
## data: c(103, 1108) out of c(420, 5482)
## X-squared = 4.1876, df = 1, p-value = 0.02036
## alternative hypothesis: greater
## 95 percent confidence interval:
## 0.006176158 1.000000000
## sample estimates:
## prop 1 prop 2
## 0.2452381 0.2021160
```

### Rezultat

p-vrijednost manja od 0.05 znači da odbacujemo  $H_0$  u korist  $H_1$ , odnosno prihvaćamo da je udio submissiona veći kod evenata koji se održavaju u Brazilu.